Dmytro Palahin

Data Engineer

Paris, France | +33 7 87 32 58 78 | dmytro.palahin@gmail.com | linkedin.com/in/dmytro-palahin | github.com/DmytroPalahin

Langues : Français - **C1** · Anglais - **C1** · Ukrainien - **natif** · Russe - **bilingue**

De la migration de données à l'outillage des équipes, une même exigence : rigueur de validation, autonomie technique et sens du besoin métier.

EXPÉRIENCE PROFESSIONNELLE

Data Engineer / MLOps (Alternance) **09/2023 - 08/2026**
Société Générale Assurances *La Défense, France*

- Conception d'un **système de migration SAS vers Python par agents IA (GitHub Copilot)** : **workflow en 5 étapes**, **Skills** spécialisées, contexte persistant (*copilot-instructions.md*), module remplaçant les macros SAS et **tests à 2 niveaux**
  - Python · Polars · DuckDB · pytest · GitHub Copilot · Prompt Engineering · SAS · AWS S3
- Automatisation d'un **pipeline de migration de 500+ Go de datasets SAS** depuis des partages réseau SMB **vers AWS S3** : benchmark de 4 bibliothèques Python, **envoi en streaming multipart** au-delà de 5 Go
  - Python · boto3 · fsspec · s3fs · smbprotocol · AWS S3 · Linux · Bash
- **Inventaire automatisé de 500+ programmes SAS** (SAS Enterprise Guide, GitLab) : métadonnées d'exécution, historique des commits, **cartographie des dépendances** et **score de priorisation de la migration**, restitués aux managers
  - Python · Pandas · Git · openpyxl · Matplotlib · Seaborn · GitLab
- Évaluation du **Callbot Zaion** sur **1 an de données** : appariement sans identifiant commun, **matrice de confusion** (environ 80 % des motifs reconnus), **arbre de décision** sur les erreurs et **3 recommandations d'amélioration**
  - Python · Pandas · NumPy · Scikit-Learn · Matplotlib · Seaborn · Plotly · Jupyter Notebook
- Déploiement d'un **dashboard Apache Superset de pilotage du Callbot** : **10+ KPI opérationnels** (identification client, durée d'appel, rappels) calculés par **requêtes SQL** sur des données JSONB PostgreSQL
  - Apache Superset · PostgreSQL · SQL
- Maintenance et **montées de version de code-server** et de **35+ extensions internes** (**40+ utilisateurs**) : tests de compatibilité, **scripts d'installation automatisés**, intégration de Ruff et BasedPyright (analyse 10x plus rapide que Flake8)
  - Linux · Bash · code-server · JupyterHub · VS Code · Ruff · BasedPyright · Git
- Développement de **3 extensions VS Code** pour **30+ Data Scientists et Data Analysts**, dont le **suivi temps réel CPU/RAM/GPU** et le **temps restant avant nettoyage** des sessions JupyterHub, utilisées au quotidien
  - TypeScript · Python · psutil · JupyterHub API · JSON · Git · VS Code

COMPÉTENCES

- **Data Engineering :** Python, SQL, Spark/PySpark, Orchestration (Airflow, Kedro), MLflow, dbt, Kafka, Jenkins, ETL/ELT, Data Pipelines/Ingestion, Data Migration, Data Modeling, Data Warehousing, SAS, FastAPI, REST APIs
- **IA & ML :** LLMs, RAG, Generative AI, AI Agents, LangChain, LangGraph, MCP, GitHub Copilot, Prompt Engineering, NLP, Deep Learning, Scikit-Learn, XGBoost, LightGBM, TensorFlow/Keras, PyTorch, Feature Engineering, Model Evaluation
- **Cloud & Data :** AWS S3, Azure, Azure OpenAI, BigQuery, PostgreSQL, MySQL, Oracle, Polars, DuckDB, Linux, NoSQL
- **Data Quality & Analytics :** Pandas, NumPy, Data Quality, Validation, Monitoring, Reporting, Apache Superset, Tableau
- **DevOps :** Java, C/C++, TS/JS, Git (GitHub), Docker, Kubernetes, CI/CD, GitHub Actions, Bash, Tests automatisés, Jira

FORMATION

École d'ingénieurs Sup Galilée - Diplôme d'ingénieur en Informatique **2023 - 2026**
Cours : Cloud Computing, Bases de données avancées et NoSQL (MongoDB, Cassandra, Redis, Elasticsearch), Data Mining, Machine Learning et Programmation pour l'IA, NLP, Génie logiciel (UML, Design Patterns), Administration système (Linux), Probabilités et Statistiques, Optimisation linéaire et combinatoire (MILP), Algorithmes parallèles et distribués, Algorithmique des graphes

Université Sorbonne Paris Nord - Classe préparatoire à Sup Galilée **2021 - 2023**
Cours : Algèbre linéaire, Analyse, Topologie et Calcul Différentiel, Probabilités, Calcul scientifique, Algorithmique, Systèmes UNIX

PROJETS IA & ENGINEERING

- **Système de détection de phishing par email** | *Python, Machine Learning, NLP* **2026**
  Classification de 76,7k emails (5 datasets réels) : NLP (TF-IDF, extraction d'URLs), ensemble LightGBM + Naive Bayes + LSTM
- **Ant Colony Optimization (ACO) for the TSP** | *C11, Métaheuristiques, Programmation dynamique* **2023**
  Bibliothèque C11 : modèle probabiliste + 2-opt, validé par Held-Karp exact (optimum sur 500/500 instances) ; 117 tests, fuzzing, CI
- **Placement de centres logistiques** | *Python, Julia, CPLEX, Optimisation* **2025**
  Projet d'optimisation combinatoire pour le placement de centres logistiques via modèles MILP résolus avec CPLEX et heuristiques
- **Système de réactions** | *Haskell* **2024**
  Représentation de systèmes et processus de réactions en programmation fonctionnelle
- **Publication d'un article** | *Algorithmes mathématiques* **2021**
  Filtration du bruit impulsionnel dans les images vidéo — *Informatics and Mathematical Methods in Simulation*, vol. 11, n° 4
- **Détection d'anomalies** | *Python, Machine Learning* **2021**
  Méthodes pour l'étiquetage partiel de données

CERTIFICATIONS

- **Udemy - Jose Portilla / Pierian Training :** *Python for Data Science and Machine Learning Bootcamp*
- **Huawei AI Certifications :** *Artificial Intelligence and Applications · Artificial Intelligence Technology and Applications*

PRIX & PARTICIPATIONS

- **Lauréat de la Fondation Georges Besse**
- **Eco-Techno Ukraine ISEF** - 1re place en Informatique
- **Service Internet Intelligence Collective** - 1re place en Ukraine

CENTRES D'INTÉRÊT

Invest · Échecs · Ski · Tennis · Natation · Karting | Formule 1